

FinBERT-768 Results

Structured + FinBERT (768-dim) — היפרפרמטרים קבועים מול Grid Search | דוח מלא: פרמטרים, זמני ריצה, כל המדדים, מימדי FinBERT שתורמו בפועל

תזה: F-TM-CR / FinBERT | סקריפטים: BASELINE_768.py , GRIDSEARCH_768.py | תאריך: אוגוסט 2026

סטטוס: שתי הריצות (dim-768, קבוע וגם Grid Search) הושלמו. הריצות המקבילות עם PCA-50 (BASELINE_PCA50.py , GRIDSEARCH_PCA50.py) בהמתנה — יתועדו בנפרד בהמשך.

1. מטרה ורקע

GRIDSEARCH.py / analysis/BASELINE.py קובעים את נקודת הייחוס המבנית (126 פיצ'רים, ללא שום אות טקסטואלי). מסמך זה בודק: האם הוספת ה-embedding הסמנטי של FinBERT (768 מימדים, sem_*, מבוסס mean-pooling) לתיאור ההלוואה (desc) משפרת את חיזוי הדיפולט — עם היפרפרמטרים קבועים לעומת כוונן per-fold.

2. הנתונים

- שורות: 217,287 (אחרי סינון) | שיעור דיפולט: 15.36%
- פיצ'רים מבניים: 126 (זהה ל-BASELINE.py)
- 768 + has_desc FinBERT: מימדי sem_000 ... sem_767 — מוזג לפי id (לא מיקום שורה), אושר 1:1 ללא שינוי במספר השורות
- 45.9% מההלוואות בעלות תיאור (desc) לא ריק
- סה"כ פיצ'רים במטריצה: 126 + 1 (has_desc) + 895 (sem_*) = 768

Walk-Forward Folds (14, זהה ל-BASELINE.py)

defaults in test	n_test	n_train	Test	≥ Train	Fold
157	1,042	6,694	2010-09 – 2010-08	2010-08 ≥	1
136	1,222	9,893	2010-12 – 2010-11	2010-11 ≥	2
184	1,369	13,674	2011-03 – 2011-02	2011-02 ≥	3
255	1,762	18,165	2011-06 – 2011-05	2011-05 ≥	4
286	1,979	23,547	2011-09 – 2011-08	2011-08 ≥	5
406	2,190	29,671	2011-12 – 2011-11	2011-11 ≥	6
413	2,781	36,786	2012-03 – 2012-02	2012-02 ≥	7
681	3,713	45,976	2012-06 – 2012-05	2012-05 ≥	8
919	5,975	59,483	2012-09 – 2012-08	2012-08 ≥	9
893	5,970	77,872	2012-12 – 2012-11	2012-11 ≥	10
1,164	8,184	98,111	2013-03 – 2013-02	2013-02 ≥	11
1,739	10,802	125,865	2013-06 – 2013-05	2013-05 ≥	12
2,007	12,846	161,023	2013-09 – 2013-08	2013-08 ≥	13

2,263	14,845	202,442	2013-12 – 2013-11	2013-11 ≥	14
-------	--------	---------	-------------------	-----------	----

3. בניית מטריצת הפיצ'רים (ללא דליפה)

- בלוק מבני:** `StandardScaler` + `SimpleImputer(fill_value=0)`, שניהם מותאמים (fit) רק על ה-train של ה-fold
- בלוק FinBERT:** `has_desc` + כל 768 עמודות `sem_*`, מוגדלות בנפרד (`StandardScaler` משלהן, fit על train בלבד), ואז `hstack` עם הבלוק המבני
- Grid Search בלבד:** בתוך כל 20% fold אחרונים (כרונולוגית) של ה-train מופרדים ל-validation זמני. `imputer/scaler` מותאמים רק על 80% הראשונים ("sub-train"), כל שילוב בגריד מוערך על ה-validation, הזוכה מאומן מחדש על כל ה-train של ה-fold לפני הערכה על ה-test האמיתי

4. פרמטרים

Walk-Forward / Bootstrap (שני הסקריפטים)

פרמטר	ערך
MIN_TRAIN_MONTHS	8
STEP_MONTHS	3
MIN_TEST_DEFAULTS	100
N_BOOTSTRAP	500
BOOT_SEED	42
RANDOM_STATE	242

היפרפרמטרים קבועים — `BASELINE_768.py` (זהה ל-`analysis/BASELINE.py`)

פרמטרים	מודל
<code>penalty=l2, C=0.3, solver=saga, class_weight=balanced</code>	Logistic
<code>n_estimators=300, max_depth=4, learning_rate=0.05, subsample=0.8, scale_pos_weight=dynamic</code>	XGBoost
<code>n_estimators=500, min_samples_leaf=20, class_weight=balanced</code>	RandomForest

גרידים — `GRIDSEARCH_768.py` (זהה ל-`analysis/GRIDSEARCH.py`, עם חריגה אחת)

RandomForest	XGBoost	Logistic
<code>min_samples_leaf ∈ {10,20,50}</code> 3 שילובים, <code>n_estimators=500</code> קבוע, זהה ל- <code>GRIDSEARCH.py</code>	<code>max_depth ∈ {3,4,6}</code> <code>learning_rate ∈ {0.05,0.1}</code> 6 שילובים, זהה ל- <code>GRIDSEARCH.py</code>	<code>C ∈ {0.01, 0.03, 0.1, 0.3, 1}</code> 5 שילובים — הורחב ל-0.01 (במקום 4 שילובים ב- <code>GRIDSEARCH.py</code>) כי הריצה המבנית נעצרה על <code>C=0.03</code> , קצה הגריד, ומטריצה רחבה פי 7 רוצה עוד רגולריזציה

תיקון זיכרון (הוחל על שני הסקריפטים)

המכונה עם 13.7GB RAM. הריצה הראשונה של `BASELINE_768.py` נעצרה (killed) אחרי 13/14 fold — כנראה OOM (202,442) fold 14: שורות × 895 עמודות, `RandomForest` עם `n_jobs=-1` על 12 ליבות). תיקון: `n_jobs` הוגבל ל-4 (`RandomForest` ו-`XGBoost`, שני הסקריפטים) + `del` מפורש + `gc.collect()` בין folds. לא משנה תוצאות (שני המודלים דטרמיניסטיים תחת `random_state` קבוע ללא תלות ב-`n_jobs`). הריצה החוזרת הצליחה במלואה.

5. זמני ריצה

סקריפט	זמן ריצה כולל	הערה
BASELINE_768.py	71.5 דקות	14 folds, ללא כוונן
GRIDSEARCH_768.py	304.7 דקות (~5.1 שעות)	הסקריפט היקר ביותר בפרויקט עד כה — מטריצה של 895 עמודות × חיפוש גריד-per fold × saga

6. תוצאות — כל המדדים (AUC, PR-AUC, Brier, GINI)

ממוצע ± סטיית תקן על פני 14 folds:

GINI	Brier	PR-AUC	AUC	גרסה	Model
0.0304 ± 0.3860	0.0151 ± 0.2313	0.0322 ± 0.2766	0.0152 ± 0.6930	Baseline — מבני בלבד (126)	Logistic
0.0306 ± 0.3860	0.0149 ± 0.2313	0.0320 ± 0.2767	0.0153 ± 0.6930	Grid Search — מבני בלבד	
0.0711 ± 0.3465	0.0161 ± 0.2326	0.0403 ± 0.2620	0.0356 ± 0.6732	FinBERT-768 — Baseline+	
0.0483 ± 0.3654	0.0148 ± 0.2289	0.0350 ± 0.2687	0.0242 ± 0.6827	FinBERT-768 — Grid Search+	
0.0383 ± 0.3808	0.0171 ± 0.2114	0.0354 ± 0.2794	0.0191 ± 0.6904	Baseline — מבני בלבד	XGBoost
0.0303 ± 0.3860	0.0148 ± 0.2177	0.0334 ± 0.2802	0.0152 ± 0.6930	Grid Search — מבני בלבד	
0.0533 ± 0.3680	0.0247 ± 0.2039	0.0407 ± 0.2760	0.0266 ± 0.6840	FinBERT-768 — Baseline+	
0.0404 ± 0.3781	0.0196 ± 0.2148	0.0391 ± 0.2777	0.0202 ± 0.6890	FinBERT-768 — Grid Search+	
0.0397 ± 0.3773	0.0135 ± 0.1877	0.0336 ± 0.2759	0.0199 ± 0.6886	Baseline — מבני בלבד	RandomForest
0.0379 ± 0.3766	0.0165 ± 0.1763	0.0333 ± 0.2752	0.0190 ± 0.6883	Grid Search — מבני בלבד	
0.0395 ± 0.3222	0.0118 ± 0.1807	0.0318 ± 0.2452	0.0197 ± 0.6611	FinBERT-768 — Baseline+	
0.0357 ± 0.3494	0.0111 ± 0.2018	0.0320 ± 0.2570	0.0179 ± 0.6747	FinBERT-768 — Grid Search+	

מסקנה מרכזית: ב-כל שלושת המודלים, על כל ארבעת המדדים (כולל PR-AUC), הוספת FinBERT-768 הגולמי פוגעת בביצועים לעומת המודל המבני בלבד — גם כשמכוונים היפרפרמטרים. הכוונן משפר חלקית (במיוחד Random Forest: AUC מ-0.6611 ל-0.6747), אבל אף גרסה לא חוזרת לרמת המודל המבני הטהור. זו הסיבה שריצות ה-PCA50 (בהמתנה) הן הצעד הבא ההגיוני.

גרפי יציבות AUC נשמרו ב- `FinBERT/figures/baseline_768/` ו- `FinBERT/figures/gridsearch_768/`

7. היפרמטרים שנבחרו לכל Fold (Grid Search)

פרמטר שנבחר	Validation AUC	n_val	n_sub	Model	Fold
C=0.01	0.6630	1,339	5,355	Logistic	1
max_depth=3, lr=0.05	0.6273	1,339	5,355	XGBoost	1
min_samples_leaf=50	0.6219	1,339	5,355	RandomForest	1
C=0.01	0.6975	1,979	7,914	Logistic	2
max_depth=3, lr=0.05	0.6903	1,979	7,914	XGBoost	2
min_samples_leaf=50	0.6695	1,979	7,914	RandomForest	2
C=0.01	0.6754	2,735	10,939	Logistic	3
max_depth=3, lr=0.05	0.6910	2,735	10,939	XGBoost	3
min_samples_leaf=50	0.6874	2,735	10,939	RandomForest	3
C=0.01	0.6822	3,633	14,532	Logistic	4
max_depth=3, lr=0.05	0.6946	3,633	14,532	XGBoost	4
min_samples_leaf=50	0.6726	3,633	14,532	RandomForest	4
C=0.01	0.6858	4,710	18,837	Logistic	5
max_depth=3, lr=0.05	0.6976	4,710	18,837	XGBoost	5
min_samples_leaf=50	0.6766	4,710	18,837	RandomForest	5
C=0.01	0.6997	5,935	23,736	Logistic	6
max_depth=3, lr=0.05	0.7038	5,935	23,736	XGBoost	6
min_samples_leaf=50	0.6885	5,935	23,736	RandomForest	6
C=0.01	0.6739	7,358	29,428	Logistic	7
max_depth=3, lr=0.05	0.6834	7,358	29,428	XGBoost	7
min_samples_leaf=50	0.6613	7,358	29,428	RandomForest	7
C=0.01	0.6870	9,196	36,780	Logistic	8
max_depth=3, lr=0.05	0.6951	9,196	36,780	XGBoost	8
min_samples_leaf=50	0.6762	9,196	36,780	RandomForest	8
C=0.01	0.6831	11,897	47,586	Logistic	9
max_depth=3, lr=0.05	0.6879	11,897	47,586	XGBoost	9
min_samples_leaf=50	0.6717	11,897	47,586	RandomForest	9
C=0.01	0.6767	15,575	62,297	Logistic	10
max_depth=3, lr=0.05	0.6807	15,575	62,297	XGBoost	10
min_samples_leaf=50	0.6607	15,575	62,297	RandomForest	10
C=0.01	0.6771	19,623	78,488	Logistic	11
max_depth=3, lr=0.05	0.6878	19,623	78,488	XGBoost	11
min_samples_leaf=50	0.6828	19,623	78,488	RandomForest	11
C=1.0	0.6958	25,173	100,692	Logistic	12

max_depth=3, lr=0.1	0.6983	25,173	100,692	XGBoost	12
min_samples_leaf=50	0.6876	25,173	100,692	RandomForest	12
C=0.3	0.7000	32,205	128,818	Logistic	13
max_depth=4, lr=0.05	0.7028	32,205	128,818	XGBoost	13
min_samples_leaf=50	0.6877	32,205	128,818	RandomForest	13
C=0.03	0.6970	40,489	161,953	Logistic	14
max_depth=4, lr=0.05	0.6994	40,489	161,953	XGBoost	14
min_samples_leaf=50	0.6900	40,489	161,953	RandomForest	14

הפרמטר הנפוץ ביותר

הערה	נפוץ ביותר (מתוך 14)	Model
נעצר בקצה התחתון של הגריד המורחב — אולי צריך עוד יותר נמוך	C=0.01 (12/14)	Logistic
עקבי עם ההעדפה של המודל המבני לעצים רדודים	max_depth=3, lr=0.05 (12/14)	XGBoost
נעצר בקצה העליון (הכי מוסדר) של הגריד — אולי צריך עוד יותר	min_samples_leaf=50 (12/14)	RandomForest

8. אילו מימדי FinBERT באמת תרמו (ניתוח מלא, לא רק Top 20)

חושב מחדש מה-fold האחרון ($n=202,442$, $\text{train} \leq 2013-11$) — אותם מודלים, אותם היפרפרמטרים קבועים כמו בריצה המלאה, כדי לחלץ את דירוג החשיבות המלא (895 פיצ'רים ל-784 Logistic/RandomForest, פיצ'רים שבפועל נעשה בהם שימוש ל-XGBoost). טבלאות מלאות: `FinBERT/results/baseline_768/feature_importance_*_FULL.csv`

הסתייגות: תחת L2 (Logistic) ו-500 עצים (RandomForest), כמעט לכל אחד מ-768 מימדי ה-`sem_*` יש משקל/חשיבות שונים מאפס — זה לא מוכיח תרומה אמיתית. המדד המשמעותי הוא ה**דירוג** (rank) יחסית ל-~900 הפיצ'רים האחרים, לא רק אם המקדם שונה מאפס.

א. סיכום לפי מודל

מודל	סה"כ פיצ'רים	מימדי <code>sem_*</code> עם תרומה >0	מימד <code>sem_*</code> המדורג הכי גבוה	דירוג גלובלי	מימדי FinBERT ב-Top 50 הגלובלי
Logistic	895	768 / 768	fb:sem_649	#17 מתוך 895	29 מתוך 50
XGBoost	784	768 / 705	fb:sem_693	#12 מתוך 784	25 מתוך 50
RandomForest	895	768 / 768	fb:sem_097	#51 מתוך 895	0 מתוך 50

זה ההסבר הישיר ביותר לפגיעה הגדולה יותר של RandomForest ($\Delta\text{AUC} = -0.0275$, קבוע, 0.0136 מכוון) — הפגיעה הגדולה ביותר בשני הריצות: RandomForest נשען כמעט לחלוטין על 126 הפיצ'רים המבניים — אף מימד FinBERT לא נכנס ל-Top 50 הגלובלי שלו — בעוד Logistic ו-XGBoost שואבים כמחצית מ-50 הפיצ'רים המובילים שלהם מ-FinBERT. זו לא בעיה של "האות לא קיים" (Logistic ו-XGBoost שניהם מוצאים אותן, ומסכימים על חלק ניכר ממנו — ראו 28) — זו התאמה בין המודל להיפרפרמטרים (`min_samples_leaf`) לבין המבנה הדליל של האות הזה.

ב. מימדי FinBERT שתרמו בעקביות בכל שלושת המודלים

חיתוך בין רשימות ה-Top 200 (מתוך ~800-900 פיצ'רים) של Logistic, RandomForest ו-XGBoost — מימדים שמדורגים כחשובים באופן עצמאי בשלושה אלגוריתמים שונים לגמרי הם האות ה"אמיתי" ביותר שניתן לתעד. **15 מימדים** עוברים את הרף הזה (טבלה מלאה: `finbert_dims_consistent_top200_all3models.csv`), ממוינים לפי סכום הדירוגים (נמוך יותר = עקבי יותר):

מימד FinBERT	דירוג LR	דירוג XGBoost	דירוג RandomForest	סכום דירוגים
fb:sem_300	64	19	57	140
fb:sem_089	22	116	70	208
fb:sem_217	103	28	90	221
fb:sem_642	32	67	127	226
fb:sem_662	104	53	85	242
fb:sem_171	72	66	123	261
fb:sem_456	99	96	72	267
fb:sem_716	102	64	102	268
fb:sem_130	101	81	88	270
fb:sem_467	151	87	75	313
fb:sem_635	85	157	91	333
fb:sem_340	92	114	148	354
fb:sem_238	18	181	162	361
fb:sem_485	75	126	181	382

417	178	105	134	fb:sem_187
-----	-----	-----	-----	------------

שני מימדים (**sem_300, sem_456** — מודגשים) מדורגים ב-Top 100 של **שלושת** המודלים בו-זמנית — האות המודל-אגנוסטי החזק ביותר שנמצא בריצה הזו.

8. פרשנות

יש אות אמיתי, לא-תלוי-מודל, ב-embedding של FinBERT — הוא לא רעש שרק אלגוריתם אחד נאחז בו במקרה. אבל הוא **מפוזר**: פרוש על פני עשרות מימדים ולא מרוכז בכמה דומיננטיים (בהשוואה ל- `int_rate` או `grade_ord`, שיושבים בדירוג 1-3# בכל מודל, בכל fold). הפיזור הזה בדיוק מה שמקשה להשתמש ב-FinBERT-768 הגולמי בצורה רווחית עם תקציב רגולריזציה קבוע ובלתי-משתנה (סעיף 6) — ומשתפר רק חלקית עם כוונן (סעיף 6). זו גם המוטיבציה הישירה לבדיקת PCA-50: אם האות באמת מפוזר על פני מימדים מתואמים רבים, שלב כיווץ שלוכד את השונות המשותפת בפחות רכיבים אמור לרכז את האות המפוזר הזה לתוך פיצ'רים שמודל עם רגולריזציה קבועה (ובמיוחד RandomForest, לפי 8א) יוכל באמת לנצל.

9. מיקומי קבצים

קובץ	נתיב
סקריפטים	FinBERT/BASELINE_768.py, FinBERT/GRIDSEARCH_768.py
תוצאות Baseline	FinBERT/results/baseline_768/
תוצאות Grid Search	FinBERT/results/gridsearch_768/ (כולל wf_best_params.csv)
חשיבות פיצ'רים מלאה	FinBERT/results/baseline_768/feature_importance_*_FULL.csv
מימדים עקביים	FinBERT/results/baseline_768/finbert_dims_consistent_top*_all3models.csv
גרפים	FinBERT/figures/baseline_768/, FinBERT/figures/gridsearch_768/
מסמך מקור (Markdown, מתעדכן)	FinBERT/RESULTS_COMPARISON.md

דוח זה נוצר אוטומטית מתוצאות BASELINE_768.py ו-GRIDSEARCH_768.py (14 folds, 217,287 שורות). תוצאות PCA-50 יתועדו בנפרד כשיושלמו.