

FinBERT Full Comparison

Structured + FinBERT — 768-dim גולמי מול PCA-50, היפרפרמטרים קבועים מול Grid Search, ומבחן DeLong | דוח מסכם

תזה: F-TM-CR / FinBERT | סקריפטים: BASELINE_PCA50.py, GRIDSEARCH_768.py, BASELINE_768.py
SAVE_PREDICTIONS_PCA50.py, SAVE_PREDICTIONS_768.py, GRIDSEARCH_PCA50.py
מסמך | תאריך: אוגוסט 2026 | מקור מלא: FinBERT/RESULTS_COMPARISON.md

הממצא המרכזי: PCA-50 מנצח 768 הגולמי בכל צירי ההשוואה — דיוק (AUC/PR-AUC), כיול (Brier), זמן ריצה (פי 4-5 מהיר יותר), ועכשיו גם באופן סטטיסטי מובהק: מבחן DeLong מזווג מראה ש-PCA50 מנצח את 768 ב-14/14 folds עבור Random Forest ו-Logistic (ללא יוצא מן הכלל!), מובהק ב-12/14 עבור XGBoost. RandomForest בלבד אדיש להבדל.

1. מטרה ושיטה

analysis/BASELINE.py קובע נקודת ייחוס מבנית (126 פיצ'רים, ללא טקסט). כאן נבדק: האם הוספת ה-embedding הסמנטי של FinBERT ל- desc משפרת חיזוי דיפולט — בשתי רזולוציות (768 מימדים גולמיים מול 50 רכיבי PCA) ובשני משטרי היפרפרמטרים (קבוע מול Grid Search per-fold), ולבסוף — האם ההבדל בין 768 ל-PCA50 מובהק סטטיסטי (DeLong). ארבעה סקריפטים עצמאיים לאימון + שני סקריפטים לשמירת תחזיות, ללא ייבוא הדדי, כולם עם אותם 126 פיצ'רים מבניים, אותם 14 folds כרונולוגיים, אותו RANDOM_STATE=242.

- נתונים:** 217,287 שורות, 15.36% דיפולט, 45.9% עם תיאור (desc) לא ריק
- FinBERT:** sem_767 ... sem_000 + has_desc (768 מימדי mean-pooling), מוזג לפי id, אושר 1:1
- PCA:** PCA(n_components=50, svd_solver='randomized', random_state=242) — מותאם מחדש בכל fold, רק על ה-train, ללא דליפה זמנית. Explained variance: 88.0%–90.2%

Walk-Forward Folds (14, זהה בכל הסקריפטים)

defaults in test	n_test	n_train	Test	≥ Train	Fold
157	1,042	6,694	2010-09 – 2010-08	2010-08 ≥	1
136	1,222	9,893	2010-12 – 2010-11	2010-11 ≥	2
184	1,369	13,674	2011-03 – 2011-02	2011-02 ≥	3
255	1,762	18,165	2011-06 – 2011-05	2011-05 ≥	4
286	1,979	23,547	2011-09 – 2011-08	2011-08 ≥	5
406	2,190	29,671	2011-12 – 2011-11	2011-11 ≥	6
413	2,781	36,786	2012-03 – 2012-02	2012-02 ≥	7
681	3,713	45,976	2012-06 – 2012-05	2012-05 ≥	8
919	5,975	59,483	2012-09 – 2012-08	2012-08 ≥	9
893	5,970	77,872	2012-12 – 2012-11	2012-11 ≥	10
1,164	8,184	98,111	2013-03 – 2013-02	2013-02 ≥	11
1,739	10,802	125,865	2013-06 – 2013-05	2013-05 ≥	12
2,007	12,846	161,023	2013-09 – 2013-08	2013-08 ≥	13

2,263	14,845	202,442	2013-12 – 2013-11	2013-11 ≥	14
-------	--------	---------	-------------------	-----------	----

2. פרמטרים

Walk-Forward / Bootstrap (כל הסקריפטים)

ערך	פרמטר
8	MIN_TRAIN_MONTHS
3	STEP_MONTHS
100	MIN_TEST_DEFAULTS
500	N_BOOTSTRAP
42	BOOT_SEED
242	RANDOM_STATE

היפרפרמטרים קבועים — `_BASELINE_768.py` / `BASELINE_PCA50.py` / `SAVE_PREDICTIONS` (זהה ל-`analysis/BASELINE.py`)

פרמטרים	מודל
<code>penalty=l2, C=0.3, solver=saga, class_weight=balanced</code>	Logistic
<code>n_estimators=300, max_depth=4, learning_rate=0.05, subsample=0.8, scale_pos_weight=dynamic</code>	XGBoost
<code>n_estimators=500, min_samples_leaf=20, class_weight=balanced</code>	RandomForest

גרידים — `GRIDSEARCH_768.py` / `GRIDSEARCH_PCA50.py` (זהה בשניהם; חריגה אחת מ-`analysis/GRIDSEARCH.py`)

RandomForest	XGBoost	Logistic
<code>min_samples_leaf ∈ {10,20,50}</code> 3 שילובים, <code>n_estimators=500</code> קבוע	<code>max_depth ∈ {3,4,6}</code> <code>learning_rate ∈ {0.05,0.1}</code> 6 שילובים	<code>C ∈ {0.01, 0.03, 0.1, 0.3, 1}</code> 5 שילובים — הורחב ל-0.01

תיקוני זיכרון וחוסן (הוחלו על כל הסקריפטים)

מכונה עם 13.7GB RAM, לרוב 4-6GB פנויים בפועל. `n_jobs` הוגבל ל-4 (RandomForest, XGBoost) + ניקוי זיכרון מפורש (`del` + `gc.collect()`) בין `fold`s. עבור מבחן ה-DeLong (סעיף 5), סקריפט משולב שמאמן את שתי הגרסאות באותו תהליך נכשל פעמיים ב-11/12/14 fold — הפתרון: פיצול לשני תהליכי OS נפרדים (`SAVE_PREDICTIONS_768.py` , `SAVE_PREDICTIONS_PCA50.py`) שרק שומרים תחזיות גולמיות, עם מנגנון checkpoint (שמירה מיידית per-fold, דילוג על `fold`s שכבר נשמרו בהרצה חוזרת).

3. זמני ריצה

זמן ריצה	מטרה	מימד FinBERT	סקריפט
71.5 דקות	אימון + הערכה, קבוע	768	BASELINE_768.py
304.7 דקות (~5.1 שעות)	אימון + הערכה, Grid Search	768	GRIDSEARCH_768.py
18.4 דקות	אימון + הערכה, קבוע	(PCA) 50	BASELINE_PCA50.py
61.6 דקות	אימון + הערכה, Grid Search	(PCA) 50	GRIDSEARCH_PCA50.py
55.8 דקות (אחרי 4 ניסיונות שנכשלו ב-OOM)	שמירת תחזיות ל-DeLong	768	SAVE_PREDICTIONS_768.py
14.7 דקות (הצליח בניסיון הראשון)	שמירת תחזיות ל-DeLong	(PCA) 50	SAVE_PREDICTIONS_PCA50.py

4. תוצאות — כל המדדים, כל 4 הגרסאות

AUC

PCA50 (Grid)	PCA50 (Baseline)	(Grid) 768	(Baseline) 768	מבני-בלבד (Grid)	מבני-בלבד (Baseline)	Model
0.6948	0.6948	0.6827	0.6732	0.6930	0.6930	Logistic
0.6921	0.6887	0.6890	0.6840	0.6930	0.6904	XGBoost
0.6857	0.6855	0.6747	0.6611	0.6883	0.6886	RandomForest

PR-AUC

PCA50 (Grid)	PCA50 (Baseline)	(Grid) 768	(Baseline) 768	מבני-בלבד (Grid)	מבני-בלבד (Baseline)	Model
0.2792	0.2790	0.2687	0.2620	0.2767	0.2766	Logistic
0.2782	0.2759	0.2777	0.2760	0.2802	0.2794	XGBoost
0.2691	0.2675	0.2570	0.2452	0.2752	0.2759	RandomForest

Brier (נמוך יותר = טוב יותר)

PCA50 (Grid)	PCA50 (Baseline)	(Grid) 768	(Baseline) 768	מבני-בלבד (Grid)	מבני-בלבד (Baseline)	Model
0.2306	0.2310	0.2289	0.2326	0.2313	0.2313	Logistic
0.2162	0.2065	0.2148	0.2039	0.2177	0.2114	XGBoost
0.1856	0.1738	0.2018	0.1807	0.1763	0.1877	RandomForest

GINI

PCA50 (Grid)	PCA50 (Baseline)	(Grid) 768	(Baseline) 768	מבני-בלבד (Grid)	מבני-בלבד (Baseline)	Model
0.3897	0.3896	0.3654	0.3465	0.3860	0.3860	Logistic
0.3843	0.3773	0.3781	0.3680	0.3860	0.3808	XGBoost
0.3714	0.3710	0.3494	0.3222	0.3766	0.3773	RandomForest

5. מבחן FinBERT-768 מול DeLong: FinBERT-PCA50 (מזווג, אותו test set)

כל ההשוואות למעלה הן מול מודל מבני-בלבד. כאן השאלה הישירה: האם 768 ו-PCA50 שונים זה מזה באופן מובהק סטטיסטית? מבחן DeLong (DeLong et al. 1988) מזווג את שתי ה-AUC על אותן שורות test בדיוק, בכל fold, עם אותם היפרפרמטרים קבועים כמו ב-BASELINE_PCA50.py / BASELINE_768.py.

Model	AUC Δ ממוצע (768-PCA50)	Folds מובהקים ($p < 0.05$)	כיוון	folds ש-PCA50 מנצח (כל מרווח)
RandomForest	0.0244+	14 / 12	100% לטובת PCA50	14 / 14
Logistic	0.0216+	14 / 6	100% לטובת PCA50	14 / 14
XGBoost	0.0046+	14 / 0	מעורב, לא מובהק	14 / 12 (לא מובהק)

עבור RandomForest ו-PCA50, Logistic מנצח את 768 בכל אחד מ-14 ה-folds, ללא יוצא מן הכלל — וב-RandomForest רוב הניצחונות (12/14) מובהקים סטטיסטית בפני עצמם, ואף פעם לא בכיוון ההפוך. זו טענה חזקה יותר מהשוואת הממוצעים בסעיף 4 בלבד: לא רק שהממוצע של PCA50 גבוה יותר — הסדר נשמר fold-אחר-fold, בעקביות. XGBoost הוא היוצא מן הכלל: אף fold לא מראה הבדל מובהק בשום כיוון — כלומר XGBoost אדיש סטטיסטית לשאלה אם FinBERT מגיע כ-768 מימדים גולמיים או 50 רכיבי PCA (עקבי עם 5c/5e, שם ה- ΔAUC מכוונן היה גם הכי קטן משלושת המודלים).

fold — RandomForest					fold — XGBoost					fold — Logistic				
p-value	Δ	AUC PCA50	AUC 768	Fold	p-value	Δ	AUC PCA50	AUC 768	Fold	p-value	Δ	AUC PCA50	AUC 768	Fold
0.6407	0.0078+	0.6246	0.6169	1	0.8747	0.0024+	0.6123	0.6099	1	0.0004	0.0787+	0.6563	0.5775	1
0.2268	0.0161+	0.6635	0.6474	2	0.2922	0.0147+	0.6903	0.6756	2	0.1132	0.0310+	0.6772	0.6462	2
0.0003	0.0455+	0.6972	0.6517	3	0.0822	0.0197+	0.6805	0.6608	3	0.0158	0.0400+	0.7008	0.6608	3
0.0032	0.0301+	0.6816	0.6514	4	0.1202	0.0150+	0.6792	0.6642	4	0.0000	0.0737+	0.7076	0.6340	4
0.0030	0.0275+	0.7101	0.6826	5	0.6121	0.0040+	0.7189	0.7149	5	0.3764	0.0096+	0.7220	0.7124	5
0.0001	0.0362+	0.6779	0.6417	6	0.4128	0.0052+	0.6796	0.6744	6	0.0792	0.0145+	0.6800	0.6655	6
0.0002	0.0291+	0.6872	0.6580	7	0.1930	0.0072-	0.6880	0.6952	7	0.2702	0.0077+	0.7006	0.6929	7
0.0000	0.0328+	0.6821	0.6493	8	0.2325	0.0053+	0.6917	0.6864	8	0.0008	0.0188+	0.6888	0.6700	8
0.0000	0.0371+	0.6969	0.6598	9	0.8723	0.0006-	0.7029	0.7035	9	0.0008	0.0139+	0.7015	0.6877	9
0.0001	0.0174+	0.6939	0.6765	10	0.2534	0.0032+	0.6936	0.6904	10	0.1646	0.0049+	0.6945	0.6896	10
0.0000	0.0165+	0.6911	0.6746	11	0.8287	0.0005-	0.6960	0.6964	11	0.2921	0.0026+	0.6955	0.6929	11
0.0000	0.0179+	0.6995	0.6815	12	0.7117	0.0005+	0.7047	0.7042	12	0.1330	0.0023+	0.7054	0.7031	12
0.0000	0.0128+	0.6893	0.6766	13	0.1617	0.0016+	0.6969	0.6953	13	0.0099	0.0037+	0.6968	0.6931	13
0.0000	0.0151+	0.7024	0.6872	14	0.0739	0.0016+	0.7066	0.7050	14	0.5387	0.0008+	0.7005	0.6997	14

שורות מודגשות (ירוק) = מובהק $p < 0.05$. טבלה מלאה: `FinBERT/results/delong_768_vs_pca50/delong_per_fold.csv`

6. אילו מימדי FinBERT באמת תרמו

ניתוח מלא (לא רק Top 20) מה-fold האחרון של BASELINE_768.py, מוצלב בין שלושת המודלים:

מודל	סה"כ פיצ'רים	מימד *_sem מדורג הכי גבוה	דירוג	FinBERT ב-Top 50 גלובלי
Logistic	895	fb:sem_649	#17	50 / 29
XGBoost	784	fb:sem_693	#12	50 / 25
RandomForest	895	fb:sem_097	#51	50 / 0

RandomForest לא מכניס אף מימד FinBERT ל-Top 50 שלו — ייתכן שזו סיבה נוספת לכך שהוא (יחד עם Logistic) מרוויח הכי הרבה מ-**הכיווץ** ל-PCA50 (סעיף 5): כשה-768 המקוריים נדחסים ל-50 רכיבים, האות המפוזר מתרכז לתוך פחות פיצ'רים, וקל יותר למודל עם רגולריזציה קבועה (כמו RandomForest עם min_samples_leaf=20) "לתפוס" אותו.

15 מימדים שתרמו בעקביות בכל שלושת המודלים (Top 200 בכולם)

מימד FinBERT	דירוג LR	דירוג XGBoost	דירוג RandomForest	סכום דירוגים
fb:sem_300	64	19	57	140
fb:sem_089	22	116	70	208
fb:sem_217	103	28	90	221
fb:sem_642	32	67	127	226
fb:sem_662	104	53	85	242
fb:sem_171	72	66	123	261
fb:sem_456	99	96	72	267
fb:sem_716	102	64	102	268
fb:sem_130	101	81	88	270
fb:sem_467	151	87	75	313
fb:sem_635	85	157	91	333
fb:sem_340	92	114	148	354
fb:sem_238	18	181	162	361
fb:sem_485	75	126	181	382
fb:sem_187	134	105	178	417

שני מימדים (sem_300, sem_456 — מודגשים) מדורגים ב-Top 100 של שלושת המודלים בו-זמנית.

האישור הישיר: PCA מרכז את האות המפוזר

ב-BASELINE_PCA50.py, רכיב PCA יחיד — fb:pca_016 — נכנס ל-Top 20 הגלובלי גם ב-XGBoost (מקום 11, Gain=82.53) וגם ב-Logistic (מקום 17). ב-768 הגולמי, לא היה אף מימד *_sem בודד שהתקרב לרמת תרומה כזו.

7. סיכום ומסקנה

1. FinBERT מכיל אות אמיתי, לא-תלוי-מודל (15 מימדים עקביים בשלושה אלגוריתמים שונים) — אבל מפוזר על פני 768 מימדים מתואמים.

2. **768 מימדים גולמיים פוגעים בביצועים** בכל שלושת המודלים, בכל המדדים, עם היפרפרמטרים קבועים — וגם אחרי +5 שעות כוונון, לא חוזרים לרמת המודל המבני.
3. **PCA-50 פותר את זה לגמרי, ובאופן מובהק סטטיסטית:** תואם/עולה על המודל המבני, מנצח את 768 ב-14/14 folds (Logistic ו-RandomForest), ופי 4-5 מהיר יותר.
4. **Logistic ו-RandomForest נהנים מהכיוון; XGBoost אדיש** — עקבי עם כך ש-XGBoost היה גם המודל הכי פחות מושפע מכוונון היפרפרמטרים.

8. מיקומי קבצים

קטגוריה	נתיב
סקריפטי אימון	FinBERT/BASELINE_768.py, GRIDSEARCH_768.py, BASELINE_PCA50.py, GRIDSEARCH_PCA50.py
סקריפטי DeLong	FinBERT/SAVE_PREDICTIONS_768.py, SAVE_PREDICTIONS_PCA50.py
תוצאות אימון	FinBERT/results/{baseline_768, gridsearch_768, baseline_pca50, gridsearch_pca50}/
תחזיות + DeLong	FinBERT/results/predictions_{768,pca50}.csv, FinBERT/results/delong_768_vs_pca50/
חשיבות פיצ'רים מלאה	FinBERT/results/baseline_768/feature_importance_*_FULL.csv
מסמך מקור (Markdown, מלא)	FinBERT/RESULTS_COMPARISON.md

דוח זה מסכם את כל הריצות (BASELINE_768.py, GRIDSEARCH_768.py, BASELINE_PCA50.py, GRIDSEARCH_PCA50.py, ומבחן DeLong) — 217,287 שורות, 14 folds כרונולוגיים בכל ריצה.