

TF-IDF Ablation Results (Hebrew)

אבלציית TF-IDF מול נתונים מובנים — תוצאות ופרמטרים

תוצאות מלאות, פרמטרים ומבחני מובהקות עבור השוואת walk-forward בין **Structured** (בסיס, ללא טקסט) לעומת **Structured+TFIDF_full** (בסיס + כל אוצר המילים של ה-TF-IDF, ללא הגבלה, per fold) לעומת **Structured+TFIDF_chi2** (בסיס + top-500 עמודות TF-IDF שנבחרו ב- χ^2 , מותאם על train בלבד), על פני Logistic Regression, XGBoost. מסמך מקביל ל- `analysis/BASELINE.py` (הבסיס המובנה בלבד) ול- `FinBERT/RESULTS_COMPARISON.md` (ההשוואה המקבילה עבור FinBERT embeddings).

1. מטרה

TF-IDF/tfidf_pipeline.py מתאים אוצר מילים TF-IDF ללא הגבלת מספר עמודות (עדיין מסונן לפי `min_df=5`) לכל fold של walk-forward (יוניגרמים+ביגרמים), אבל לא מאמן ולא מעריך שום מודל עליו. הסקריפט הזה (TF-IDF/tfidf_structured_ablation.py) סוגר את הפער: האם הוספת TF-IDF משפרת את חיזוי ה-default לעומת הבסיס המובנה בלבד, וכמה מהתרומה הזו נשמרת כשמצמצמים את אוצר המילים לקבוצה קטנה וניתנת לפירוש של מילים/ביגרמים באמצעות בחירת פיצ'רים ב- χ^2 — שהרי כל הרעיון בשימוש ב-TF-IDF במקום embedding צפוף הוא הסבריות (interpretability)?

2. נתונים

- קובץ המקור: `data/03_advanced_prep/lc_after_03_advanced_prep_basic+test_20260715_2119.csv`
- שורות אחרי סינון (`is_default ∈ {0,1}`): 217,287
- שיעור default: 15.36%
- פיצ'רים מובנים: 126 (הגדרת `STRUCT_COLS` ל- `analysis/BASELINE.py`)
- מקור ה-TF-IDF: `TF-IDF/output/fold{NN}/*.npz` — חושב מראש על ידי `tfidf_pipeline.py` (לא חושב מחדש כאן), `ngram_range=(1,2)`, `min_df=5`, `sublinear_tf=True`, אוצר מילים ללא הגבלה.

פולדי Walk-Forward (זהים ל- `analysis/BASELINE.py` / `tfidf_pipeline.py`, נבדק 14) (=

expanding) folds 14 → `MIN_TEST_DEFAULTS=100`, `STEP_MONTHS=3`, `MIN_TRAIN_MONTHS=8` (window), מ-2010-08 עד 2013-12.

n_defaults	n_test	n_train	test_end	train_cutoff	Fold
157	1,042	6,694	2010-09	2010-08	1
136	1,222	9,893	2010-12	2010-11	2
184	1,369	13,674	2011-03	2011-02	3
255	1,762	18,165	2011-06	2011-05	4
286	1,979	23,547	2011-09	2011-08	5
406	2,190	29,671	2011-12	2011-11	6
413	2,781	36,786	2012-03	2012-02	7
681	3,713	45,976	2012-06	2012-05	8
919	5,975	59,483	2012-09	2012-08	9
893	5,970	77,872	2012-12	2012-11	10
1,164	8,184	98,111	2013-03	2013-02	11
1,739	10,802	125,865	2013-06	2013-05	12
2,007	12,846	161,023	2013-09	2013-08	13
2,263	14,845	202,442	2013-12	2013-11	14

גודל אוצר המילים וזמני ריצה, לכל fold

רוחב הזרוע המלאה גדל עם ה-fold (חלון אימון מתרחב → אוצר מילים גדול יותר שעובר `min_df=5`); זרוע ה-chi2 קבועה על 500 עמודות בכל fold. זמן הריצה הוא העלות המעשית העיקרית של הזרוע המלאה — XGBoost ו-RandomForest שניהם מתאמנים על המטריצה ה-sparse המלאה (עד 55,028 עמודות + 126 TF-IDF מובנות, fold 14).

Fold	אוצר מילים TF-IDF (זרוע מלאה)	זמן ריצה ל-fold (3 זרועות × 3 מודלים)
1	6,227	55 שני'
2	8,624	81 שני'
3	11,226	101 שני'
4	13,672	122 שני'
5	16,504	156 שני'
6	19,081	197 שני'
7	21,482	248 שני'
8	24,356	365 שני'
9	29,073	524 שני'
10	34,317	758 שני'
11	39,208	1032 שני'
12	44,235	997 שני'
13	49,606	1362 שני'
14	55,028	1788 שני'

סך זמן הריצה: 129.7 דקות (~2.2 שעות), כל 14 ה-folds, רץ כשהליך רקע מנותק (`n_jobs=4`) ל-RandomForest/XGBoost בשתי זרועות ה-TF-IDF, לצורך בטיחות זיכרון על מחשב עם 13.7GB RAM).

3. בניית מטריצת הפיצ'רים (ללא דליפת מידע)

- **בלוק מובנה:** `SimpleImputer(strategy="constant", fill_value=0, keep_empty_features=True)`
 - `StandardScaler`, שניהם מותאמים על שורות ה-TRAIN של ה-fold בלבד. (`keep_empty_features=True`) היה תיקון באג שהתגלה במהלך הפיתוח — בפולדים המוקדמים יש עמודות מובנות שהן NaN לחלוטין בפרוסת האימון הקטנה של אותו fold; בלי זה, `SimpleImputer` מוחק אותן בשקט, ומייצר חוסר-סנכרון בין רשימת שמות הפיצ'רים לבין המודל המותאם בפועל.)
- **Structured+TFIDF_full:** `scipy.sparse.hstack([structured_sparse, tfidf_train_full])` — מטריצת ה-TF-IDF המלאה של ה-fold, ללא צמצום.
- **Structured+TFIDF_chi2:** `SelectKBest(chi2, k=500)` מותאם על בלוק ה-TF-IDF של שורות ה-TRAIN בלבד (לעולם לא נוגע בבלוק המובנה — עמודות מובנות אף פעם לא מועמדות להסרה), ואז אותן העמודות הנבחרות מיושמות על מטריצת ה-TF-IDF של שורות ה-TEST (עמודות ה-train וה-test מיושרות לפי אינדקס בכל fold, כי `tfidf_pipeline.py` התאים את ה-vectorizer על train ואז עשה `.transform()` על test עם אותו vectorizer).
- כל התאמת המודלים בשתי זרועות ה-TF-IDF נשארת **sparse** מקצה לקצה (ללא הפיכה ל-dense) — `saga` (Logistic), RandomForest ו-XGBoost כולם תומכים ב-קלט CSR sparse באופן טבעי.
- שמות פיצ'רים שמקורם ב-TF-IDF מקבלים תחילית `txt:` כדי למנוע התנגשות שמות שהתגלתה בגרסה קודמת של הפייפליין (עמודה מובנית בשם `term` התנגשה עם טוקן TF-IDF שגם הוא `term`).

4. פרמטרים

Walk-forward / bootstrap

פרמטר	ערך
MIN_TRAIN_MONTHS	8
STEP_MONTHS	3
MIN_TEST_DEFAULTS	100
N_BOOTSTRAP	500
BOOT_SEED	42
RANDOM_STATE	242
CHI2_TOP_K	500

היפרפרמטרים קבועים (זהים בכל 3 הזרועות — לקוחים במדויק מ- `analysis/BASELINE.py`, ללא כיוונון נפרד לכל זרוע)

מודל	פרמטרים
Logistic	<code>penalty=l2, C=0.3, solver=saga, max_iter=1000, class_weight=balanced</code>
XGBoost	<code>n_estimators=300, max_depth=4, learning_rate=0.05, subsample=0.8, scale_pos_weight=דינמי (neg/pos fold), eval_metric=auc</code>
RandomForest	<code>n_estimators=500, min_samples_leaf=20, class_weight=balanced</code>

הוחלט במפורש **לא** לכווון בנפרד לכל זרוע (בשונה מ- `FinBERT/finbert_structured_ablation.py`, שכן מכווון רגולריזציה בנפרד לכל זרוע) — סוויפ רגולריזציה מלא היה מכפיל התאמת RandomForest שכבר מסוכנת מבחינת RAM/זמן על נתונים sparse רחבים (עד ~55K עמודות) ב-4-5 מועמדים נוספים $3 \times$ folds כיוונון, לתועלת לא ודאית ביחס לזמן הריצה הנוסף (ההרצה בפועל כבר לקחה 130 דקות עם היפרפרמטרים קבועים).

`n_jobs` : -1 — לזרוע Structured (קטנה/dense, זהה ל- `BASELINE.py` במדויק); 4 — לשתי זרועות ה-TF-IDF (בטיחות RAM על התאמות sparse רחבות של RandomForest/XGBoost על המחשב הזה).

5א. ביצועים חזויים מלאים — ממוצע $\pm$ סטיית תקן על פני 14 folds

זרוע	מודל	AUC	PR-AUC	Brier	GINI
Structured	Logistic	0.0152 $\pm$ 0.6930	0.0322 $\pm$ 0.2766	0.0151 $\pm$ 0.2313	0.0304 $\pm$ 0.3860
Structured	XGBoost	0.0191 $\pm$ 0.6904	0.0354 $\pm$ 0.2794	0.0171 $\pm$ 0.2114	0.0383 $\pm$ 0.3808
Structured	RandomForest	0.0199 $\pm$ 0.6882	0.0354 $\pm$ 0.2740	0.0142 $\pm$ 0.1891	0.0398 $\pm$ 0.3764
Structured+TFIDF_full	Logistic	0.0159 $\pm$ 0.6965	0.0318 $\pm$ 0.2818	0.0154 $\pm$ 0.2268	0.0318 $\pm$ 0.3930
Structured+TFIDF_full	XGBoost	0.0186 $\pm$ 0.6936	0.0273 $\pm$ 0.2827	0.0193 $\pm$ 0.2167	0.0373 $\pm$ 0.3872
Structured+TFIDF_full	RandomForest	0.0183 $\pm$ 0.6824	0.0289 $\pm$ 0.2700	0.0127 $\pm$ 0.2268	0.0366 $\pm$ 0.3647
Structured+TFIDF_chi2	Logistic	0.0164 $\pm$ 0.6942	0.0307 $\pm$ 0.2791	0.0151 $\pm$ 0.2308	0.0328 $\pm$ 0.3884
Structured+TFIDF_chi2	XGBoost	0.0204 $\pm$ 0.6936	0.0298 $\pm$ 0.2799	0.0173 $\pm$ 0.2166	0.0408 $\pm$ 0.3872
Structured+TFIDF_chi2	RandomForest	0.0210 $\pm$ 0.6870	0.0329 $\pm$ 0.2753	0.0137 $\pm$ 0.2069	0.0420 $\pm$ 0.3740

5ב. מבחן מובהקות DeLong (מזוג, אותו test set, לכל fold)

מודל	השוואה (B מול A)	ממוצע Δ AUC (B-A)	folds מובהקים ($p < 0.05$)
Logistic	Structured+TFIDF_full מול Structured	0.0035+	7/14
Logistic	Structured+TFIDF_chi2 מול Structured	0.0012+	2/14
Logistic	Structured+TFIDF_chi2 מול Structured+TFIDF_full	0.0023-	8/14
XGBoost	Structured+TFIDF_full מול Structured	0.0032+	3/14
XGBoost	Structured+TFIDF_chi2 מול Structured	0.0032+	2/14
XGBoost	Structured+TFIDF_chi2 מול Structured+TFIDF_full	0.0000+	0/14
RandomForest	Structured+TFIDF_full מול Structured	0.0058-	7/14
RandomForest	Structured+TFIDF_chi2 מול Structured	0.0012-	3/14
RandomForest	Structured+TFIDF_chi2 מול Structured+TFIDF_full	0.0046+	6/14

- **Logistic:** TF-IDF (המלא) משפר לעומת Structured ($\Delta AUC = +0.0035$, מובהק ב-7/14 folds). צמצום ל-500 המילים הנבחרות ב- χ^2 שומר על רוב התרומה של הזרוע המלאה (χ^2 מול Structured: $\Delta AUC = +0.0012$, מובהק ב-2/14 folds; מלא מול χ^2 : $\Delta AUC = +0.0023$, מובהק ב-8/14 folds). הזרוע הטובה ביותר בסה"כ: Structured+TFIDF_full.
- **XGBoost:** TF-IDF (המלא) משפר לעומת Structured ($\Delta AUC = +0.0032$, מובהק ב-3/14 folds). צמצום ל-500 המילים הנבחרות ב- χ^2 שומר כמעט על כל התרומה של הזרוע המלאה (χ^2 מול Structured: $\Delta AUC = +0.0032$, מובהק ב-2/14 folds; מלא מול χ^2 : $\Delta AUC = -0.0000$, מובהק ב-0/14 folds). הזרוע הטובה ביותר בסה"כ: Structured+TFIDF_ χ^2 .
- **RandomForest:** TF-IDF (המלא) לא משפר לעומת Structured ($\Delta AUC = -0.0058$, מובהק ב-7/14 folds). צמצום ל-500 המילים הנבחרות ב- χ^2 שומר על רוב התרומה של הזרוע המלאה (χ^2 מול Structured: $\Delta AUC = -0.0012$, מובהק ב-3/14 folds; מלא מול χ^2 : $\Delta AUC = -0.0046$, מובהק ב-6/14 folds). הזרוע הטובה ביותר בסה"כ: Structured.

6. אילו מילות TF-IDF תרמו בפועל (זרוע χ^2 , כל 14 ה-folds)

עקביות בין folds: עבור כל מודל, אילו מילים נבחרו על ידי χ^2 ועד כמה המודל עצמו (לא הציון הסטטיסטי של χ^2) דירג אותן בגובה, על פני 14 folds שאומנו באופן בלתי-תלוי. מילה שמופיעה ברוב/בכל ה-folds, עם דירוג חשיבות גבוה בעקביות, היא המועמדת החזקה ביותר להיכלל במודל סופי שאינו walk-forward — היא נגזרה מחדש באופן בלתי-תלוי בכל פעם, ולא נבחרה פעם אחת על כל מערך הנתונים.

מילה	fold	שנבחרה בהם	דירוג ממוצע	חלק ממוצע בחשיבות	ציון chi2 ממוצע
help	14/14	(100%)	17.8	0.0060	4.59
ring	14/14	(100%)	18.2	0.0058	5.51
ups	14/14	(100%)	20.8	0.0055	5.74
engagement	14/14	(100%)	25.3	0.0052	6.45
engagement ring	14/14	(100%)	42.9	0.0042	5.18
apr	13/14	(93%)	9.5	0.0077	5.20
pool	13/14	(93%)	25.6	0.0092	11.85
mta	13/14	(93%)	65.4	0.0040	10.44
motorcycle	13/14	(93%)	108.6	0.0028	3.75
help foot	13/14	(93%)	293.8	0.0013	4.41
trailer	12/14	(86%)	53.9	0.0036	2.72
excellent credit	12/14	(86%)	104.6	0.0026	3.43
pay problem	12/14	(86%)	149.2	0.0020	3.19
buster	12/14	(86%)	160.8	0.0020	3.53
payday	12/14	(86%)	219.1	0.0018	3.31
college	11/14	(79%)	2.5	0.0119	4.57
university	11/14	(79%)	6.7	0.0105	6.33
walmart	11/14	(79%)	45.1	0.0043	5.33
harbor	11/14	(79%)	73.9	0.0031	4.01
good payer	11/14	(79%)	127.8	0.0022	7.58

מילה	fold's שנבחרה בהם	דירוג ממוצע	חלק ממוצע בחשיבות	ציון chi2 ממוצע
engagement	(100%) 14/14	12.7	0.0065	6.45
ring	(100%) 14/14	17.1	0.0062	5.51
help	(100%) 14/14	67.3	0.0045	4.59
ups	(100%) 14/14	106.9	0.0040	5.74
engagement ring	(100%) 14/14	220.8	0.0021	5.18
motorcycle	(93%) 13/14	23.2	0.0057	3.75
apr	(93%) 13/14	37.9	0.0053	5.20
pool	(93%) 13/14	73.0	0.0052	11.85
mta	(93%) 13/14	121.2	0.0040	10.44
help foot	(93%) 13/14	257.8	0.0011	4.41
excellent credit	(86%) 12/14	103.2	0.0040	3.43
pay problem	(86%) 12/14	106.4	0.0039	3.19
trailer	(86%) 12/14	107.1	0.0041	2.72
payday	(86%) 12/14	222.8	0.0022	3.31
buster	(86%) 12/14	440.2	0.0003	3.53
college	(79%) 11/14	15.4	0.0063	4.57
university	(79%) 11/14	17.7	0.0061	6.33
refinance	(79%) 11/14	21.8	0.0057	5.39
harbor	(79%) 11/14	107.3	0.0039	4.01
good payer	(79%) 11/14	148.7	0.0032	7.58

מילה	fold's שנבחרה בהם	דירוג ממוצע	חלק ממוצע בחשיבות	ציון chi2 ממוצע
help	(100%) 14/14	34.6	0.0073	4.59
ring	(100%) 14/14	79.6	0.0010	5.51
engagement	(100%) 14/14	80.4	0.0010	6.45
engagement ring	(100%) 14/14	93.1	0.0006	5.18
ups	(100%) 14/14	195.9	0.0000	5.74
apr	(93%) 13/14	55.2	0.0028	5.20
pool	(93%) 13/14	78.5	0.0013	11.85
motorcycle	(93%) 13/14	79.0	0.0010	3.75
mta	(93%) 13/14	263.6	0.0000	10.44
help foot	(93%) 13/14	278.5	0.0000	4.41
excellent credit	(86%) 12/14	70.3	0.0019	3.43
trailer	(86%) 12/14	192.1	0.0001	2.72
payday	(86%) 12/14	223.8	0.0000	3.31
pay problem	(86%) 12/14	252.2	0.0000	3.19
buster	(86%) 12/14	435.8	0.0000	3.53
college	(79%) 11/14	51.9	0.0030	4.57
refinance	(79%) 11/14	55.6	0.0022	5.39
university	(79%) 11/14	57.2	0.0022	6.33
walmart	(79%) 11/14	121.5	0.0002	5.33
harbor	(79%) 11/14	289.7	0.0000	4.01

מועמדות לפיצ'רים במודל סופי: המילים שלמעלה שנבחרו ב-12/+14 folds אצל כל שלושת המודלים (help, ring, engagement, engagement ring, ups, apr, pool, motorcycle, mta, excellent credit) הן הפיצ'רים המוצדקים ביותר של TF-IDF להעביר למודל סופי שאינו walk-forward.

TF-IDF/results/ablation_folds.csv	מודל x זרוע x fold מדדים לכל AUC/PR-AUC/Brier/GINI + 95% CI
TF-IDF/results/ablation_summary.csv	לפי (זרוע, מודל), folds ממוצע +/- סטיית תקן על פני
TF-IDF/results/ablation_delong.csv	זוג-זרועות x מודל x fold זוגי לכל DeLong מבחן
TF-IDF/results/ablation_feature_importance.csv	פיצ'ר: חשיבות/דירוג x מודל x זרוע x fold לכל
TF-IDF/results/ablation_feature_consistency.csv	chi2-של המילים שנבחרו בזרוע ה folds-יציבות בין
TF-IDF/results/ablation_report.md	דוח מלא (אנגלית)
TF-IDF/TFIDF_ABLATION_RESULTS.pdf	דוח PDF (אנגלית)
TF-IDF/TFIDF_ABLATION_RESULTS_HE.pdf	זה (עברית) PDF דוח
TF-IDF/figures/fig1_auc_by_fold.png	לכל מודל, 3 זרועות יחד, fold לכל AUC
TF-IDF/figures/fig2_delong_deltas.png	זוג-זרועות, צבוע לפי מובהקות x לכל מודל Δ AUC תרשים עמודות